Mục lục

1 Giới thiệu tổng quan **4**
- 1.1 Tổng quan về bài toán dự báo . . . 4
- 1.2 Mô tả tập dữ liệu . . . 4
- 1.3 Mục tiêu nghiên cứu . . . 5

2 Phân tích và Tiền xử lý dữ liệu **5**
- 2.1 Khám phá dữ liệu sơ bộ . . . 5
  - 2.1.1 Cấu trúc tập dữ liệu . . . 6
  - 2.1.2 Thống kê mô tả . . . 6
- 2.2 Phân tích khám phá dữ liệu (Exploratory Data Analysis) . . . 6
  - 2.2.1 Phân phối của biến mục tiêu . . . 7
  - 2.2.2 Tác động của ngày lễ (Holidays) . . . 7
  - 2.2.3 Phân tích tương quan (Correlation Analysis) . . . 8
- 2.3 Tiền xử lý dữ liệu (Data Pre-processing) . . . 9
  - 2.3.1 Chuyển đổi đặc trưng thời gian (Date Feature Engineering) . . . 9
  - 2.3.2 Xử lý dữ liệu ngoại lai (Outlier Handling) . . . 9
  - 2.3.3 Mã hóa biến phân loại (Encoding) . . . 10
  - 2.3.4 Phân chia tập dữ liệu . . . 10

3 Phương pháp dự báo nhu cầu truyền thống **10**
- 3.1 Xử lý và biến đổi dữ liệu (Data Manipulation) . . . 10
- 3.2 Trích xuất và lựa chọn đặc trưng . . . 10
- 3.3 Triển khai các mô hình hồi quy . . . 11
  - 3.3.1 Hồi quy tuyến tính đa biến (Multiple Linear Regression - MLR) . . . 11
  - 3.3.2 Hồi quy Lasso (Lasso Regularization) . . . 11
  - 3.3.3 Hồi quy Ridge (Ridge Regularization) . . . 11
  - 3.3.4 Hồi quy Elastic Net (Elastic Net Regularization) . . . 11
  - 3.3.5 Hồi quy đa thức (Polynomial Regression Model) . . . 12
- 3.4 Tổng hợp kết quả các phương pháp dự báo truyền thống . . . 12

4 Dự báo nhu cầu bằng các phương pháp thống kê (Statistical Time Series Forecasting) **13**
- 4.1 Trung bình trượt (Moving Average) . . . 13
- 4.2 San bằng mũ đơn (Simple Exponential Smoothing . . . 14
- 4.3 San bằng mũ kép có điều chỉnh xu hướng (Double Smoothing with Damped Trend) . . . 14
- 4.4 San bằng mũ ba (Triple Exponential Smoothing / Holt-Winters) . . . 14
- 4.5 Tổng hợp kết quả các phương pháp thống kê . . . 15

5 Dự báo nhu cầu bằng các mô hình học máy (Machine Learning) **16**
- 5.1 Cây quyết định (Decision Tree) . . . 17
  - 5.1.1 Mô hình tập trung (Centralized) . . . 17
  - 5.1.2 Mô hình phi tập trung (Decentralized) . . . 18
- 5.2 Rừng ngẫu nhiên (Random Forest) . . . 18
  - 5.2.1 Mô hình tập trung (Centralized) . . . 18
  - 5.2.2 Mô hình phi tập trung (Decentralized) . . . 19
- 5.3 Cây tăng cường Gradient (Gradient-Boosted Tree) . . . 19

5.3.1 Mô hình tập trung (Centralized) 19
5.3.2 Mô hình phi tập trung (Decentralized) 20
5.4 Phân cụm K-means (K-means Clustering) 20
5.4.1 Xây dựng đặc trưng phân cụm 20
5.4.2 Tối ưu hóa số lượng cụm (K) 20
5.5 Phân cụm dựa trên mật độ (DBSCAN Clustering) 21
5.5.1 Cơ chế hoạt động 21
5.5.2 Tinh chỉnh tham số và Kết quả 22
5.6 Tổng hợp kết quả các phương pháp học máy 22

6 Đánh giá hiệu quả và Trực quan hóa kết quả **23**
6.1 Tổng hợp kết quả thực nghiệm 23
6.2 So sánh giá trị dự báo và thực tế (Predicted vs. Actual Values) 24
6.3 Đánh giá độ ổn định theo tỷ lệ chia dữ liệu (Robustness to Split Ratio) . . 25

7 Kết luận và Kiến nghị **25**
7.1 Kết luận 25
7.2 Hạn chế và hướng phát triển 26
7.2.1 Hạn chế 26
7.2.2 Hướng phát triển 27

Tài liệu tham khảo **28**

1 Giới thiệu tổng quan

1.1 Tổng quan về bài toán dự báo

Trong lĩnh vực quản trị chuỗi cung ứng (Supply Chain Management - SCM), dự báo nhu cầu (Demand Forecasting) đóng vai trò nền tảng và mang tính chiến lược. Đây là quá trình ước tính số lượng sản phẩm hoặc dịch vụ mà khách hàng sẽ tiêu thụ trong tương lai dựa trên dữ liệu lịch sử và các yếu tố tác động khác. Độ chính xác của dự báo ảnh hưởng trực tiếp đến toàn bộ quy trình vận hành, từ lập kế hoạch sản xuất, quản lý tồn kho đến phân phối và logistics.

Một hệ thống dự báo hiệu quả giúp doanh nghiệp giải quyết bài toán tối ưu hóa tồn kho (Inventory Optimization): giảm thiểu chi phí lưu kho do dư thừa hàng hóa (Overstock) đồng thời ngăn chặn tình trạng "cháy hàng"(Stock-out) dẫn đến mất doanh thu và giảm uy tín thương hiệu. Đặc biệt trong ngành bán lẻ (Retail), nơi nhu cầu biến động mạnh theo tính mùa vụ và các sự kiện khuyến mãi, áp lực dự báo chính xác càng trở nên cấp thiết.

Sự bùng nổ của dữ liệu lớn (Big Data) đã thúc đẩy việc áp dụng Khoa học dữ liệu (Data Science) vào bài toán này. So với các phương pháp định tính hoặc thống kê mô tả đơn giản, các kỹ thuật Học máy (Machine Learning) và Chuỗi thời gian hiện đại (Advanced Time Series) cho phép xử lý khối lượng dữ liệu lớn đa chiều và phát hiện các mối quan hệ phi tuyến tính phức tạp giữa các biến số kinh tế vĩ mô và hành vi tiêu dùng.

1.2 Mô tả tập dữ liệu

Đồ án sử dụng bộ dữ liệu **Walmart Store Sales**, bao gồm dữ liệu lịch sử bán hàng của 45 cửa hàng Walmart tọa lạc tại các khu vực khác nhau. Dữ liệu trải dài trong khoảng thời gian từ **05/02/2010 đến 01/11/2012**.

Tập dữ liệu bao gồm các trường thông tin (fields) chính sau đây:

- **Store (Biến định danh):** Mã số đại diện cho cửa hàng (Store number).
- **Date (Biến thời gian):** Tuần bán hàng tương ứng.
- **Weekly_Sales (Biến mục tiêu):** Doanh số bán hàng hàng tuần của cửa hàng (đơn vị tiền tệ). Đây là biến phụ thuộc (Target variable) cần dự báo.
- **Holiday_Flag (Biến nhị phân):** Chỉ báo cho biết tuần đó có chứa ngày lễ đặc biệt hay không.
  - Giá trị 1: Tuần lễ có ngày lễ (Holiday week).
  - Giá trị 0: Tuần lễ bình thường (Non-holiday week).
- **Temperature (Biến liên tục):** Nhiệt độ trung bình trong ngày bán hàng (đơn vị Fahrenheit), ảnh hưởng đến thói quen mua sắm và nhu cầu các mặt hàng theo mùa.
- **Fuel_Price (Biến liên tục):** Giá nhiên liệu tại khu vực cửa hàng. Sự biến động giá nhiên liệu có thể tác động đến chi phí vận chuyển và ngân sách chi tiêu của người tiêu dùng.
- **CPI (Consumer Price Index):** Chỉ số giá tiêu dùng hiện hành, phản ánh mức độ lạm phát và sức mua của người dân tại khu vực đó.

- **Unemployment (Biến liên tục):** Tỷ lệ thất nghiệp hiện hành trong khu vực, là chỉ số kinh tế vĩ mô quan trọng tác động tiêu cực hoặc tích cực đến nhu cầu tiêu dùng.

Đặc biệt, biến **Holiday_Flag** được xác định dựa trên 4 sự kiện lễ hội lớn trong năm, bao gồm:

1. **Super Bowl:** Diễn ra vào tháng 2 (ví dụ: 12-Feb-10, 11-Feb-11, 10-Feb-12).
2. **Labour Day:** Diễn ra vào tháng 9 (ví dụ: 10-Sep-10, 9-Sep-11, 7-Sep-12).
3. **Thanksgiving:** Diễn ra vào tháng 11 (ví dụ: 26-Nov-10, 25-Nov-11, 23-Nov-12). Đây thường là dịp có doanh số cao nhất trong năm (Black Friday).
4. **Christmas:** Diễn ra vào cuối tháng 12 (ví dụ: 31-Dec-10, 30-Dec-11, 28-Dec-12).

1.3 Mục tiêu nghiên cứu

Mục tiêu cốt lõi của đồ án là xây dựng và tối ưu hóa các mô hình định lượng để dự báo doanh số bán hàng hàng tuần (`Weekly_Sales`). Cụ thể, nghiên cứu tập trung vào các nhiệm vụ sau:

1. **Xây dựng mô hình dự báo:** Áp dụng đa dạng các phương pháp từ thống kê truyền thống (như Exponential Smoothing) đến các thuật toán học máy hiện đại (như Random Forest) nhằm tìm ra mô hình có khả năng tổng quát hóa tốt nhất.
2. **Tối thiểu hóa sai số dự báo:** Sử dụng các chỉ số đánh giá hiệu suất như Căn bậc hai trung bình bình phương sai số (RMSE - Root Mean Squared Error) và Sai số tuyệt đối trung bình (MAE - Mean Absolute Error) làm hàm mục tiêu để tối ưu hóa tham số mô hình.
3. **Phân tích tác động của biến ngoại sinh:** Đánh giá mức độ ảnh hưởng của các yếu tố kinh tế vĩ mô (CPI, Thất nghiệp, Giá nhiên liệu) và các sự kiện ngày lễ (Holiday Events) đến biến động doanh thu.
4. **So sánh hiệu quả phương pháp:** Đưa ra các nhận định về ưu và nhược điểm của việc áp dụng mô hình học máy so với các phương pháp chuỗi thời gian truyền thống trong bối cảnh dữ liệu bán lẻ thực tế.

2 Phân tích và Tiền xử lý dữ liệu

2.1 Khám phá dữ liệu sơ bộ

Dựa trên kết quả thực nghiệm, em tổng hợp thông tin cấu trúc và thống kê mô tả của tập dữ liệu Walmart như sau:

2.1.1 Cấu trúc tập dữ liệu

Tập dữ liệu bao gồm **6,435** bản ghi và không có giá trị khuyết (missing values). Các biến được phân loại thành biến định lượng và định tính như Bảng 1.

Bảng 1: Cấu trúc các biến trong tập dữ liệu

Tên biến	Kiểu dữ liệu	Số lượng Non-Null	Mô tả
Store	int64	6435	Mã định danh cửa hàng
Date	datetime64	6435	Thời gian bán hàng
Weekly_Sales	float64	6435	Biến mục tiêu (Doanh số)
Holiday_Flag	int64	6435	Biến định danh ngày lễ (0/1)
Temperature	float64	6435	Nhiệt độ trung bình
Fuel_Price	float64	6435	Giá nhiên liệu
CPI	float64	6435	Chỉ số giá tiêu dùng
Unemployment	float64	6435	Tỷ lệ thất nghiệp

2.1.2 Thống kê mô tả

Bảng 2 tóm tắt các tham số thống kê cơ bản của các biến số thực. Điều này giúp nhận diện quy mô, độ biến động và các giá trị ngoại lai tiềm ẩn.

Bảng 2: Thống kê mô tả các biến định lượng

Biến số	Trung bình (Mean)	Độ lệch chuẩn (Std)	Min	Trung vị (50%)	Max
Weekly_Sales	1,046,965	564,366	209,986	960,746	3,818,686
Temperature	60.66	18.44	-2.06	62.67	100.14
Fuel_Price	3.36	0.46	2.47	3.45	4.47
CPI	171.58	39.36	126.06	182.62	227.23
Unemployment	8.00	1.88	3.88	7.87	14.31
Holiday_Flag	0.07	0.26	0.00	0.00	1.00

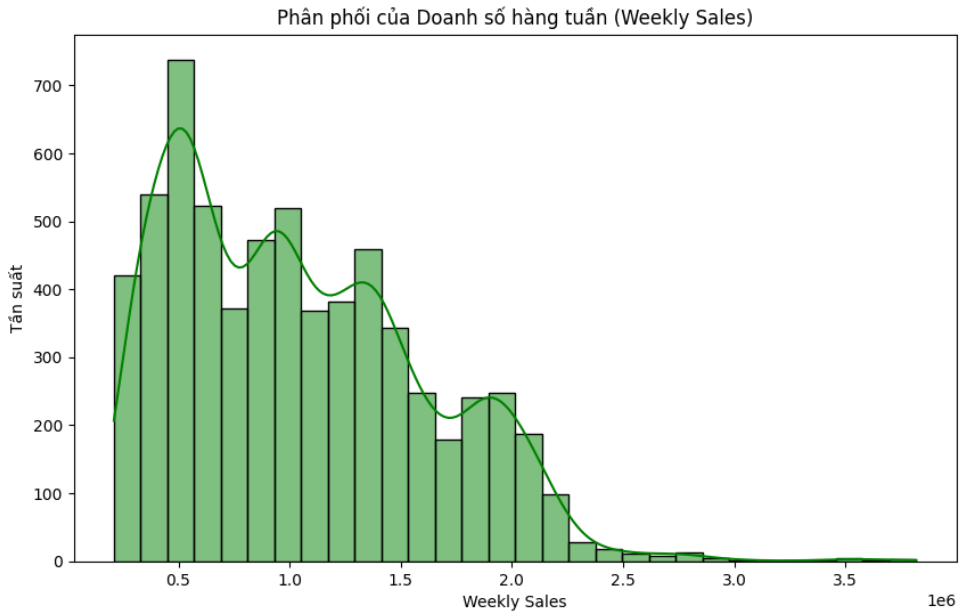
Nhận xét:

- **Weekly_Sales:** Có độ lệch chuẩn rất lớn ($std \approx 564k$), cho thấy sự phân tán mạnh của dữ liệu. Khoảng cách giữa giá trị lớn nhất (Max $\approx 3.8M$) và trung vị ($\approx 960k$) gợi ý sự tồn tại của các điểm ngoại lai (outliers) tích cực, thường rơi vào các tuần lễ lớn.
- **Temperature:** Dải nhiệt độ rộng từ -2.06 đến 100.14 độ F phản ánh tính đa dạng địa lý của các cửa hàng trên toàn nước Mỹ.
- **Holiday_Flag:** Giá trị trung bình 0.07 cho thấy các tuần lễ chỉ chiếm khoảng 7% tổng số dữ liệu, đây là bài toán dữ liệu mất cân bằng (imbalanced data) cần lưu ý khi mô hình hóa.

2.2 Phân tích khám phá dữ liệu (Exploratory Data Analysis)

Quá trình phân tích khám phá (EDA) tập trung vào việc trực quan hóa các mối quan hệ và phân phối của dữ liệu.

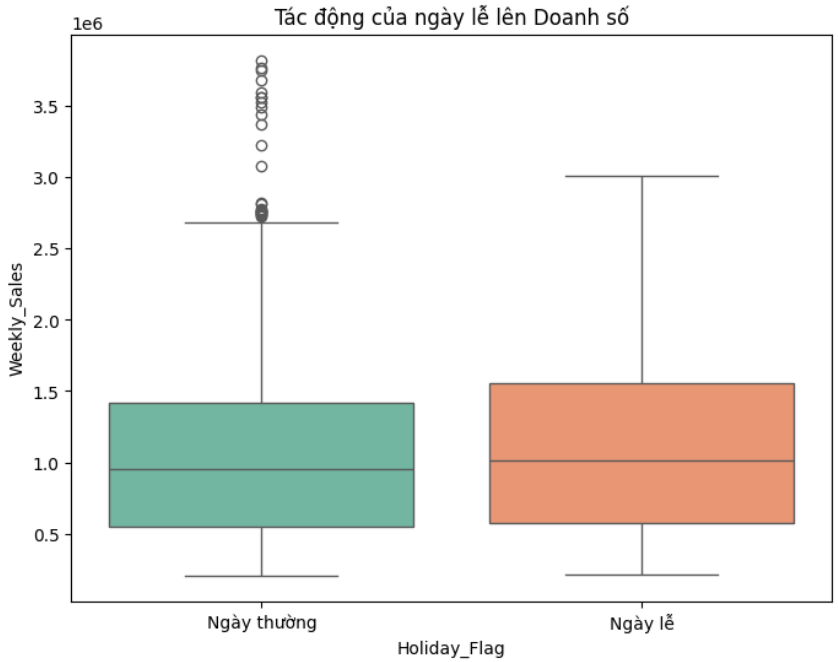
2.2.1 Phân phối của biến mục tiêu



Hình 1: Phân phối doanh số bán hàng hàng tuần

Biểu đồ phân phối (Histogram) của `Weekly_Sales` cho thấy dữ liệu có độ lệch phải (Right-skewed). Phần lớn doanh số hàng tuần tập trung ở mức trung bình, nhưng có một số lượng nhỏ các tuần đạt doanh số cực cao (các điểm ngoại lai), tương ứng với các dịp lễ lớn trong năm.

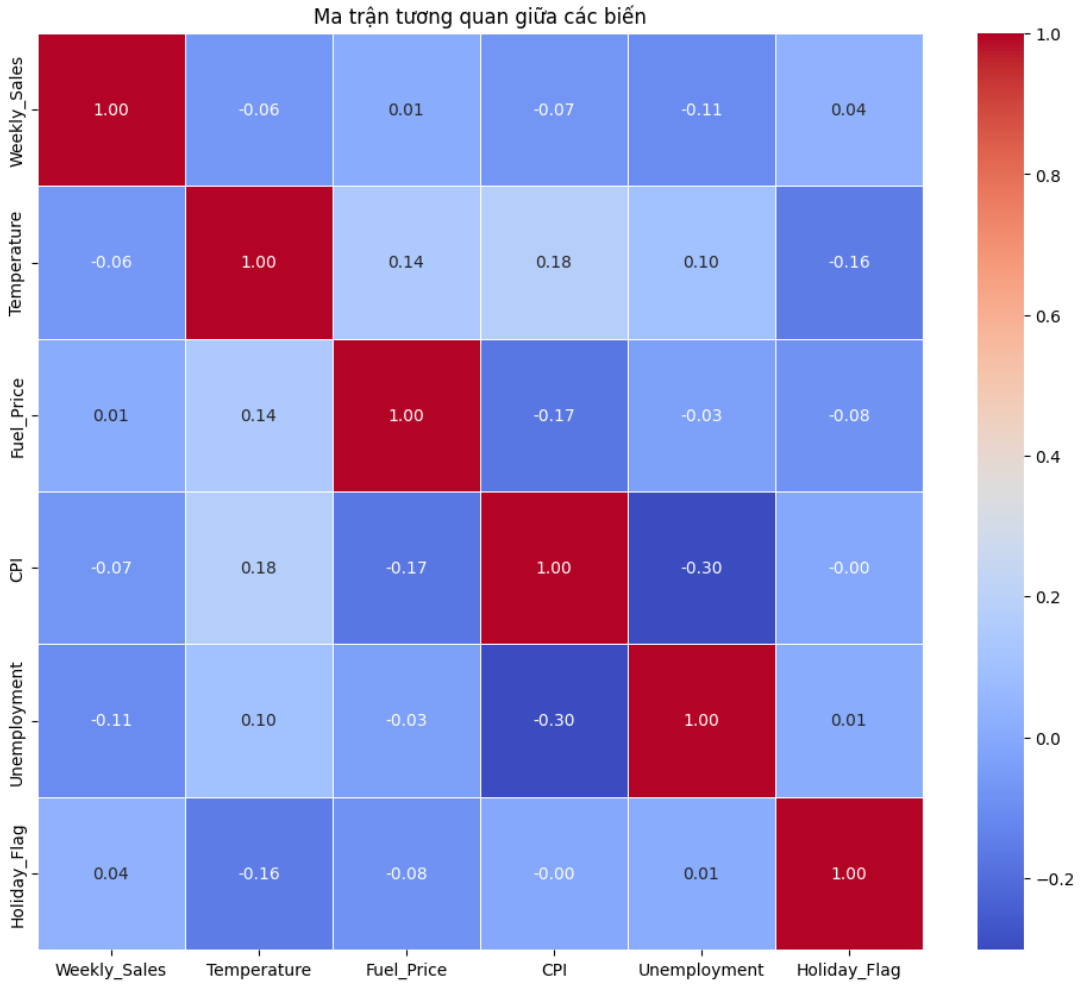
2.2.2 Tác động của ngày lễ (Holidays)



Hình 2: So sánh doanh số giữa tuần lễ và tuần thường

Biểu đồ hộp (Boxplot) so sánh giữa các tuần lễ có ngày lễ (`Holiday_Flag = 1`) và tuần thường (`Holiday_Flag = 0`) cho thấy sự khác biệt rõ rệt. Các tuần lễ thường có giá trị trung vị cao hơn và xuất hiện nhiều điểm ngoại lai phía trên (outliers), khẳng định giả thuyết rằng ngày lễ là yếu tố kích cầu quan trọng.

2.2.3 Phân tích tương quan (Correlation Analysis)



Hình 3: Ma trận tương quan giữa các biến số

Dựa trên ma trận tương quan (Hình 3), em kiểm tra mối quan hệ tuyến tính giữa các biến độc lập và biến mục tiêu:

- Các biến kinh tế vĩ mô như `Unemployment` (Thất nghiệp) và `CPI` có hệ số tương quan nghịch biến nhưng rất thấp với doanh số (lần lượt là -0.11 và -0.07).
- `Fuel_Price` (Giá nhiên liệu) có hệ số tương quan gần như bằng 0 (0.01), cho thấy biến động giá nhiên liệu không có tác động tuyến tính trực tiếp đến doanh số bán lẻ hàng tuần.
- Biến `Temperature` (Nhiệt độ) có tương quan âm nhẹ (-0.06), phản ánh tính mùa vụ (mùa đông doanh số thường cao hơn do các kỳ nghỉ lễ).

- **Kết luận:** Mức độ tương quan tuyến tính thấp giữa các biến vĩ mô và doanh số mục tiêu hàm ý rằng các mô hình hồi quy đơn giản (Linear Regression) sẽ gặp nhiều thách thức trong việc giảm thiểu sai số dự báo. Tuy nhiên, để đảm bảo tính chặt chẽ của quy trình phân tích, đồ án sẽ phân tích theo quy trình từ các phương pháp dự báo truyền thống đến các mô hình dự báo học máy.

    1. Triển khai các **phương pháp Truyền thống** (mục 3) nhằm định lượng mức độ giải thích của các biến đầu vào và thiết lập mức hiệu năng cơ sở (baseline).
    2. Áp dụng các **phương pháp Thống kê Chuỗi thời gian** (mục 4) để nắm bắt các đặc trưng về xu hướng và mùa vụ mà ma trận tương quan chưa phản ánh đầy đủ.
    3. Cuối cùng, sử dụng các **mô hình Học máy** (mục 5) để giải quyết bài toán phi tuyến tính và tối ưu hóa độ chính xác dự báo.

2.3 Tiền xử lý dữ liệu (Data Pre-processing)

Dựa trên kết quả EDA, các bước tiền xử lý sau đã được thực hiện để chuẩn bị dữ liệu tối ưu cho quá trình huấn luyện mô hình:

2.3.1 Chuyển đổi đặc trưng thời gian (Date Feature Engineering)

Cột `Date` ban đầu ở dạng chuỗi ký tự được chuyển đổi sang định dạng `datetime`. Từ đó, các đặc trưng mới được trích xuất bao gồm:

- **Day, Month, Year:** Để nắm bắt xu hướng dài hạn và tính mùa vụ theo tháng.
- **Week:** Tuần trong năm (1-52), đây là đặc trưng quan trọng nhất để mô hình học được chu kỳ mua sắm (ví dụ: tuần 47 là Lễ Tạ Ơn, tuần 51 là Giáng Sinh).

Sau khi trích xuất, cột `Date` gốc được loại bỏ để tránh đa cộng tuyến và dư thừa dữ liệu.

2.3.2 Xử lý dữ liệu ngoại lai (Outlier Handling)

Sử dụng phương pháp Khoảng tứ phân vị (Interquartile Range - IQR) để phát hiện và xử lý các điểm dữ liệu bất thường trên các biến định lượng (`Temperature`, `Fuel_Price`, `CPI`, `Unemployment`).

$$IQR = Q3 - Q1 \tag{1}$$

Các điểm dữ liệu nằm ngoài khoảng $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ được xem là ngoại lai.

- **Kết quả thực nghiệm:** Từ 6,435 bản ghi ban đầu, hệ thống đã phát hiện và loại bỏ **518** bản ghi ngoại lai (chiếm khoảng 8% dữ liệu).
- **Dữ liệu sạch:** Số lượng mẫu còn lại là **5,917** bản ghi. Việc loại bỏ này giúp mô hình không bị lệch bởi các giá trị nhiễu, đặc biệt là trong các biến kinh tế vĩ mô.

2.3.3 Mã hóa biến phân loại (Encoding)

Các biến phân loại như `Store` (45 cửa hàng), `Holiday_Flag` và các biến thời gian được chuyển đổi sang dạng số học. Phương pháp *One-Hot Encoding* (sử dụng hàm `get_dummies`) được áp dụng.

- **Kết quả:** Kích thước dữ liệu mở rộng từ 11 cột lên **54 đặc trưng** (features). Việc gia tăng số chiều này cho phép mô hình nắm bắt được đặc điểm riêng biệt của từng cửa hàng và từng năm.

2.3.4 Phân chia tập dữ liệu

Dữ liệu sạch (5,917 mẫu) được chia thành hai tập theo tỷ lệ 80/20 với `random_state=42` để đảm bảo tính tái lập:

- **Tập huấn luyện (Training Set): 4,733** mẫu (53 đặc trưng đầu vào, 1 biến mục tiêu). Dùng để huấn luyện tham số mô hình.
- **Tập kiểm tra (Test Set): 1,184** mẫu. Dùng để đánh giá độc lập hiệu suất dự báo (Unseen data).

3 Phương pháp dự báo nhu cầu truyền thống

Trong mục này, em áp dụng các mô hình hồi quy thống kê cơ bản để thiết lập mức hiệu suất cơ sở (baseline) cho bài toán dự báo doanh số Walmart. Quy trình bao gồm xử lý dữ liệu, lựa chọn đặc trưng và triển khai 5 biến thể của mô hình hồi quy.

3.1 Xử lý và biến đổi dữ liệu (Data Manipulation)

Các mô hình hồi quy, đặc biệt là các mô hình có điều chuẩn (Regularization) như Lasso hay Ridge, rất nhạy cảm với thang đo của dữ liệu. Do đó, em thực hiện chuẩn hóa dữ liệu (Standardization) bằng kỹ thuật *Standard Scaler*:

$$z = \frac{x - \mu}{\sigma} \tag{2}$$

Trong đó, μ là trung bình và σ là độ lệch chuẩn của biến. Việc này đưa tất cả các biến định lượng (như CPI, Unemployment, Fuel_Price) về cùng một phân phối chuẩn $N(0, 1)$, giúp thuật toán hội tụ nhanh hơn và các hệ số hồi quy có thể so sánh được với nhau.

3.2 Trích xuất và lựa chọn đặc trưng

Sau quá trình mã hóa One-Hot (ở mục 2), số chiều dữ liệu tăng lên đáng kể (hơn 50 đặc trưng), dẫn đến nguy cơ đa cộng tuyến (multicollinearity). Để giải quyết vấn đề này, em sử dụng phương pháp **Loại bỏ đặc trưng đệ quy (Recursive Feature Elimination - RFE)**.

Quy trình RFE thực hiện như sau:

1. Huấn luyện mô hình hồi quy tuyến tính trên toàn bộ tập đặc trưng.
2. Xếp hạng các đặc trưng dựa trên trọng số (hệ số hồi quy).

3. Loại bỏ đặc trưng ít quan trọng nhất và lặp lại quá trình.

Kết quả thực nghiệm đã chọn ra 20 đặc trưng quan trọng nhất để đưa vào các mô hình dự báo tiếp theo, giúp giảm nhiễu và chi phí tính toán.

3.3 Triển khai các mô hình hồi quy

3.3.1 Hồi quy tuyến tính đa biến (Multiple Linear Regression - MLR)

Đây là mô hình đơn giản nhất, giả định mối quan hệ tuyến tính giữa các biến đầu vào và doanh số bán hàng.

- **Kết quả:** Mô hình đạt $RMSE \approx 288,862$ và $R^2 \approx 0.7368$.
- **Nhận xét:** Với R^2 đạt xấp xỉ 74%, mô hình MLR cho thấy các biến đầu vào đã giải thích được phần lớn sự biến thiên của doanh số. Đây là một mức cơ sở (baseline) khá tốt, tuy nhiên sai số tuyệt đối vẫn còn lớn.

3.3.2 Hồi quy Lasso (Lasso Regularization)

Sử dụng chuẩn $L1$ để thêm thành phần phạt vào hàm mất mát nhằm triệt tiêu các biến ít quan trọng:

$$J(\theta) = MSE + \alpha \sum |\theta_i| \tag{3}$$

- **Kết quả:** $RMSE \approx 288,862$ và $R^2 \approx 0.7368$.
- **Nhận xét:** Kết quả của Lasso gần như tương đồng hoàn toàn với MLR. Điều này cho thấy sau bước chọn đặc trưng RFE, các biến còn lại đều có đóng góp quan trọng và Lasso không cần loại bỏ thêm biến nào đáng kể.

3.3.3 Hồi quy Ridge (Ridge Regularization)

Sử dụng chuẩn $L2$ ($\alpha \sum \theta_i^2$) để giảm thiểu độ lớn của các hệ số, giúp mô hình tránh hiện tượng quá khớp (overfitting) khi có đa cộng tuyến.

- **Kết quả:** $RMSE \approx 288,892$ và $R^2 \approx 0.7367$.
- **Nhận xét:** Hiệu năng của Ridge thấp hơn một chút so với MLR (không đáng kể). Điều này chứng tỏ hiện tượng quá khớp (overfitting) không phải là vấn đề nghiêm trọng đối với tập dữ liệu này khi sử dụng mô hình tuyến tính.

3.3.4 Hồi quy Elastic Net (Elastic Net Regularization)

Là sự kết hợp tuyến tính giữa Lasso và Ridge.

- **Kết quả:** $RMSE \approx 292,859$ và $R^2 \approx 0.7294$.
- **Nhận xét:** Elastic Net cho kết quả kém nhất trong nhóm các mô hình tuyến tính. Nguyên nhân có thể do việc tối ưu hóa hàm mục tiêu chưa hội tụ (như cảnh báo ConvergenceWarning trong quá trình chạy code), đòi hỏi phải tinh chỉnh kỹ hơn các tham số α và $l1_ratio$.

3.3.5 Hồi quy đa thức (Polynomial Regression Model)

Để nắm bắt các mối quan hệ phi tuyến, đồ án mở rộng không gian đặc trưng bằng cách thêm các biến bậc 2 (Degree = 2) từ các đặc trưng đã chọn bởi RFE.

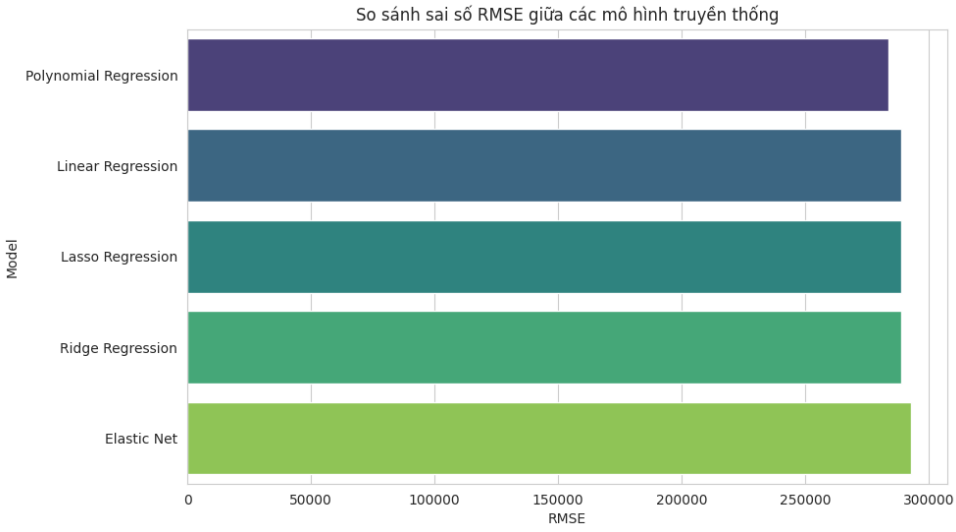
- **Kết quả:** $RMSE \approx 283,732$ và $R^2 \approx 0.7460$.
- **Nhận xét:** Đây là mô hình tốt nhất trong nhóm phương pháp truyền thống. Việc giảm RMSE xuống khoảng 5,000 đơn vị so với MLR cho thấy dữ liệu có chứa các mối quan hệ phi tuyến tính mà các mô hình bậc 1 không nắm bắt được.

3.4 Tổng hợp kết quả các phương pháp dự báo truyền thống

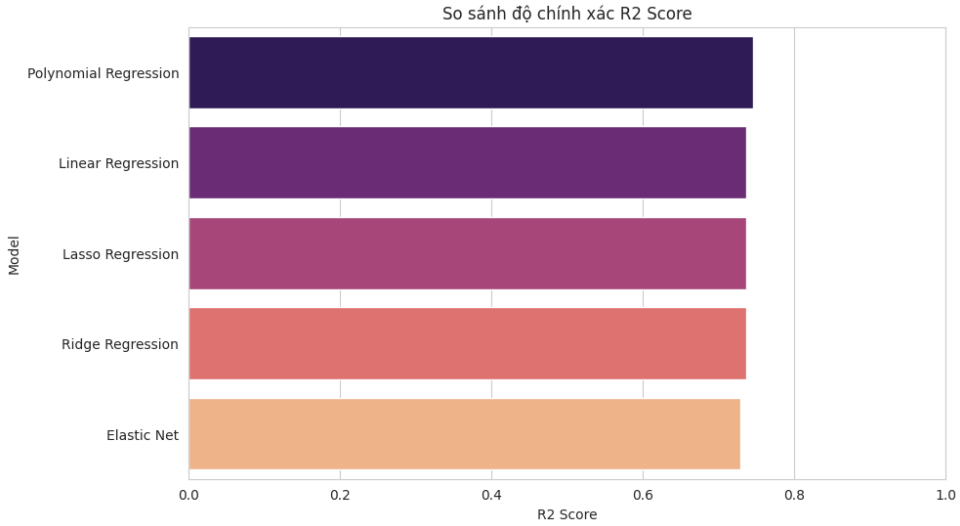
Bảng 3 dưới đây tóm tắt hiệu quả của các phương pháp truyền thống trên tập kiểm tra (Test Set). Đồng thời, Hình 4 và Hình 5 trực quan hóa sự chênh lệch giữa các mô hình.

Bảng 3: Tổng hợp kết quả các mô hình hồi quy truyền thống

Mô hình	RMSE	R2 Score
Polynomial Regression (Deg 2)	**283,732.41**	**0.7460**
Linear Regression	288,862.05	0.7368
Lasso Regression	288,862.24	0.7368
Ridge Regression	288,892.84	0.7367
Elastic Net	292,859.57	0.7294



Hình 4: So sánh sai số RMSE giữa các mô hình hồi quy truyền thống



Hình 5: So sánh độ chính xác R^2 Score giữa các mô hình

Kết luận: Dựa trên cả hai chỉ số RMSE và R^2, Hồi quy đa thức (Polynomial Regression) cho kết quả vượt trội nhất nhờ khả năng mô hình hóa đường cong doanh số, đạt độ giải thích khoảng 74.6% sự biến thiên của dữ liệu. Các mô hình tuyến tính (Linear, Lasso, Ridge) có hiệu năng tương đương nhau, trong khi Elastic Net hoạt động kém hiệu quả nhất trong thử nghiệm này.

Tuy nhiên, các mô hình hồi quy (như Đa thức) vẫn chưa xử lý triệt để được tính phụ thuộc thời gian (tự tương quan) và tính mùa vụ phức tạp theo chu kỳ tuần/năm. Trước khi áp dụng các thuật toán Học máy phức tạp, đồ án sẽ xem xét các phương pháp **Dự báo Chuỗi thời gian Thống kê (Statistical Time Series)**. Đây là các phương pháp chuyên biệt để bóc tách các thành phần Xu hướng (Trend) và Mùa vụ (Seasonality), vốn là đặc trưng cốt lõi của dữ liệu Walmart.

4 Dự báo nhu cầu bằng các phương pháp thống kê (Statistical Time Series Forecasting)

Sau khi đánh giá các phương pháp hồi quy, em nhận thấy hạn chế trong việc nắm bắt tính mùa vụ phức tạp. Do đó, ở bước này em áp dụng các mô hình thuộc họ **Exponential Smoothing (ETS)**. Đây là nhóm phương pháp được thiết kế chuyên biệt để xử lý dữ liệu chuỗi thời gian có các thành phần: Mức độ (Level), Xu hướng (Trend) và Mùa vụ (Seasonality).

Để thực hiện các phương pháp này, dữ liệu được tổng hợp (aggregated) thành tổng doanh số hàng tuần của toàn bộ hệ thống, tạo thành một chuỗi thời gian đơn biến.

4.1 Trung bình trượt (Moving Average)

Phương pháp Trung bình trượt được sử dụng như một mô hình cơ sở (baseline). Dự báo cho giai đoạn $t+1$ là trung bình cộng của k giai đoạn trước đó.

$$F_{t+1} = \frac{1}{k} \sum_{i=t-k+1}^{t} Y_i \tag{4}$$

Đồ án chọn cửa sổ trượt $k = 4$ (tương đương 1 tháng).

- **Kết quả:** $RMSE \approx 7,139,890$ và $MAE \approx 4,968,987$.
- **Nhận xét:** Phương pháp này có sai số cao nhất, phản ứng chậm với các thay đổi (độ trễ lớn) và hoàn toàn không bắt kịp các đỉnh doanh số vào dịp lễ.

4.2 San bằng mũ đơn (Simple Exponential Smoothing

SES phù hợp cho dữ liệu không có xu hướng hoặc mùa vụ rõ ràng. Công thức cập nhật mức độ L_t:

$$L_t = \alpha Y_t + (1 - \alpha)L_{t-1} \tag{5}$$

Kết quả: Do dữ liệu Walmart có xu hướng và mùa vụ rất mạnh, SES chỉ dự báo được một đường đi ngang (flat line) đại diện cho mức trung bình. Sai số vẫn ở mức rất cao ($RMSE \approx 6,953,870$).

4.3 San bằng mũ kép có điều chỉnh xu hướng (Double Smoothing with Damped Trend)

Mô hình này (còn gọi là Holt's Linear) bổ sung thêm thành phần xu hướng T_t. Để tránh việc dự báo xu hướng tăng vô tận gây sai lệch lớn trong dài hạn, đồ án sử dụng tham số tắt dần (damping parameter ϕ).

- **Kết quả:** $RMSE \approx 6,078,567$ và $MAE \approx 4,105,980$.
- **Nhận xét:** Về mặt số học, đây là mô hình có sai số thấp nhất trong nhóm thống kê. Lý do là mô hình tạo ra một đường xu hướng mượt mà đi qua trung tâm của dữ liệu, tránh được các sai số lớn do dự báo sai lệch biên độ dao động. Tuy nhiên, mô hình này thất bại trong việc mô tả tính chất mùa vụ (các đỉnh nhọn tháng 11, 12).

4.4 San bằng mũ ba (Triple Exponential Smoothing / Holt-Winters)

Đây là mô hình phù hợp nhất về mặt lý thuyết cho dữ liệu Walmart. Mô hình tích hợp cả 3 thành phần:

- **Level (Mức độ)**
- **Trend (Xu hướng)**
- **Seasonality (Mùa vụ):** Với chu kỳ $m = 52$ (tuần).

Em sử dụng mô hình Mùa vụ nhân (Multiplicative Seasonality) vì quan sát thấy biên độ dao động doanh số có xu hướng tăng lên khi tổng doanh số tăng.

Kết quả thực nghiệm:

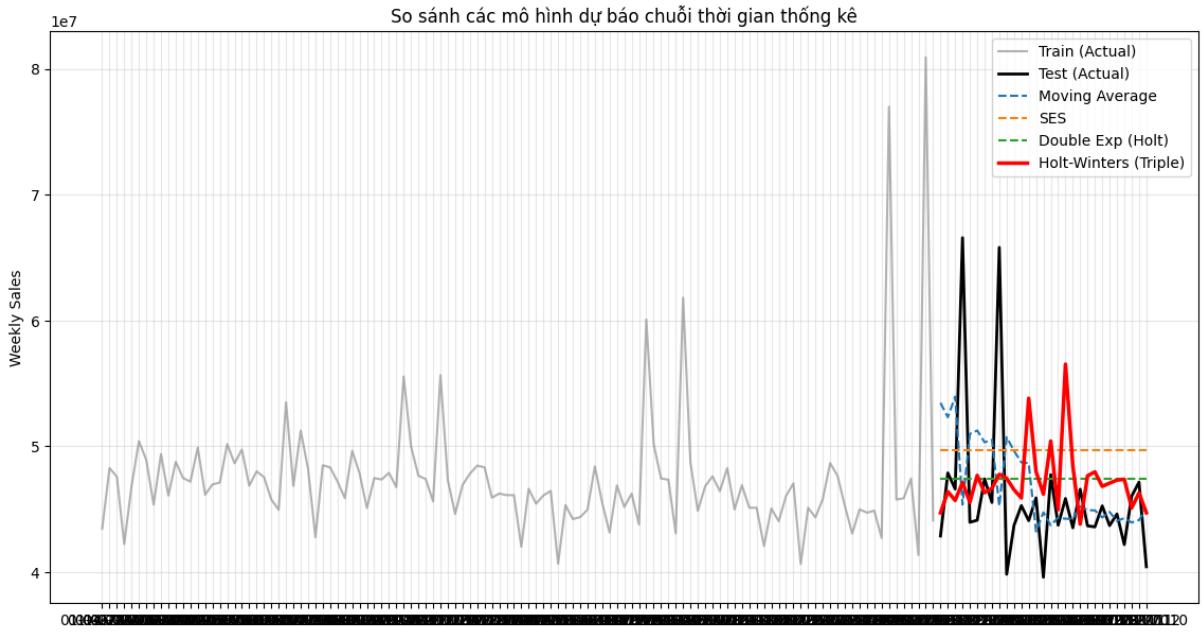
- $RMSE \approx 6,419,511$ và $MAE \approx 4,418,335$.
- **Nhận xét:** Mặc dù RMSE cao hơn mô hình Double Smoothing đôi chút, Holt-Winters là mô hình duy nhất nắm bắt được cấu trúc mùa vụ (các đỉnh doanh số dịp Giáng sinh). Việc RMSE cao hơn có thể do hiện tượng "lệch pha"(phase shift) khi dự báo chính xác thời điểm xảy ra đỉnh doanh số trên tập kiểm tra.

4.5 Tổng hợp kết quả các phương pháp thống kê

Bảng 4 và Hình 6 so sánh hiệu quả của các mô hình thống kê.

Bảng 4: Kết quả các mô hình chuỗi thời gian thống kê (Đơn vị: Triệu USD)

Mô hình	**RMSE**	**MAE**
Moving Average (k=4)	7,139,890	4,968,987
Simple Exp Smoothing	6,953,870	5,963,987
Double Exp (Damped)	**6,078,567**	**4,105,980**
Holt-Winters (Triple)	6,419,511	4,418,335



Hình 6: So sánh trực quan các phương pháp dự báo thống kê

Phân tích chi tiết biểu đồ (Hình 6):

Quan sát biểu đồ so sánh giữa dữ liệu thực tế (đường màu đen - Test Actual) và các đường dự báo, em rút ra các nhận định quan trọng sau:

- **Đặc điểm dữ liệu thực tế (Đường đen):** Dữ liệu kiểm tra (Test set) thể hiện sự biến động mạnh mẽ (high volatility) với nhiều đỉnh và đáy nhọn liên tiếp. Điều này khẳng định tính chất phức tạp và khó lường của doanh số bán lẻ trong ngắn hạn, nơi nhu cầu không đi theo một đường thẳng mượt mà.
- **Các mô hình cơ bản (Đường cam và xanh lá):**
  - Mô hình *SES* (đường đứt nét màu cam) dự báo một đường nằm ngang cố định. Nó thất bại hoàn toàn trong việc nắm bắt xu hướng giảm hoặc các dao động tuần.
  - Mô hình *Double Exponential Smoothing* (đường đứt nét màu xanh lá) dự báo một đường xu hướng đi ngang (gần như tuyến tính) nằm ở trung tâm của đám

mây dữ liệu thực tế. Chính chiến lược "trung bình hóa"này giúp nó đạt được sai số RMSE thấp nhất. Nó không cố gắng dự báo các đỉnh nhọn, do đó tránh được các sai phạt lớn khi dự báo sai biên độ.

- **Mô hình Holt-Winters (Đường đỏ):** Đây là đường dự báo duy nhất cố gắng mô phỏng lại nhịp điệu dao động của dữ liệu thực tế.
  - *Ưu điểm:* Đường màu đỏ bám sát được các thời điểm đảo chiều (turning points) của đường màu đen tốt hơn hẳn các mô hình khác.
  - *Nhược điểm:* Tại một số thời điểm (ví dụ: khoảng giữa tập Test), mô hình Holt-Winters dự báo một đỉnh tăng trưởng rất mạnh (spike) dựa trên chu kỳ lịch sử, nhưng thực tế doanh số lại không tăng cao như kỳ vọng. Sự chênh lệch biên độ (Amplitude error) tại các điểm này chính là nguyên nhân khiến RMSE của nó cao hơn Double Smoothing.

Tóm lại: Về mặt con số (RMSE), mô hình Double Smoothing hiệu quả nhờ sự ổn định. Tuy nhiên, về mặt hành vi (Behavior), Holt-Winters là mô hình duy nhất có khả năng nắm bắt cấu trúc mùa vụ. Để khắc phục hiện tượng dự báo quá mức (overshooting) của Holt-Winters, việc tích hợp thêm các biến ngoại sinh (như sự kiện khuyến mãi, ngày lễ cụ thể) thông qua các mô hình Học máy ở chương sau là bước đi cần thiết.

Kết luận: Qua thực nghiệm, mô hình Double Smoothing cho sai số thấp nhất nhờ tính ổn định, trong khi Holt-Winters thể hiện khả năng nắm bắt hành vi khách hàng (mùa vụ) tốt hơn. Tuy nhiên, các phương pháp thống kê này bộc lộ hạn chế khi chỉ sử dụng chuỗi đơn biến (Univariate) và khó tích hợp các biến ngoại sinh quan trọng như giá xăng, nhiệt độ hay chỉ số CPI. Đây là động lực để em đi đến các phương pháp cuối cùng: Sử dụng các mô hình Học máy (Machine Learning) để kết hợp ưu điểm của cả hai phương pháp.

5 Dự báo nhu cầu bằng các mô hình học máy (Machine Learning)

Tiếp theo sau đây, em áp dụng các thuật toán học máy phi tuyến tính để khắc phục các hạn chế của mô hình hồi quy và chuỗi thời gian truyền thống. Đồ án thực hiện triển khai hai chiến lược tiếp cận dữ liệu chính:

- **Mô hình tập trung (Centralized):** Huấn luyện một mô hình duy nhất trên toàn bộ dữ liệu của 45 cửa hàng. Mô hình này tận dụng lượng dữ liệu lớn để học các quy luật chung (như tính mùa vụ của các ngày lễ quốc gia) và giảm thiểu nguy cơ quá khớp (overfitting).

- **Mô hình phi tập trung (Decentralized):** Huấn luyện 45 mô hình riêng biệt, mỗi mô hình tương ứng với một cửa hàng. Cách tiếp cận này cho phép nắm bắt các đặc thù địa phương (như hành vi khách hàng tại từng bang), giảm độ chệch (bias) nhưng có thể tăng phương sai (variance) nếu dữ liệu từng cửa hàng không đủ lớn.

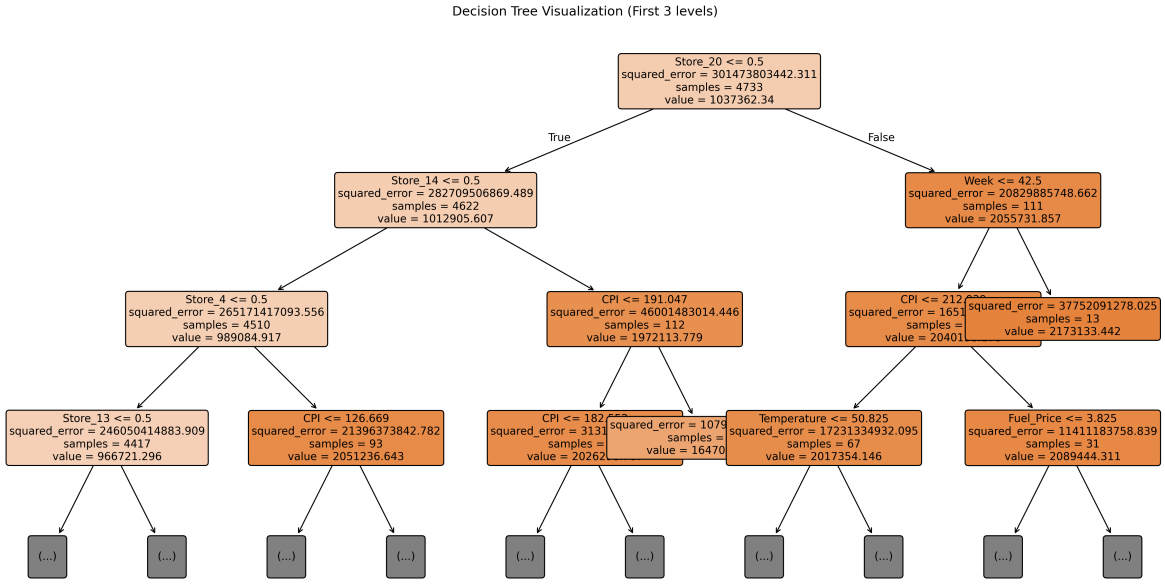
5.1 Cây quyết định (Decision Tree)

5.1.1 Mô hình tập trung (Centralized)

Mô hình được xây dựng trên toàn bộ dữ liệu. Để kiểm soát độ phức tạp, em mở rộng không gian tìm kiếm tham số bao gồm:

- `max_depth`: Độ sâu tối đa của cây.
- `min_samples_split`: Số lượng mẫu tối thiểu cần thiết để phân chia một nút.
- `min_samples_leaf`: Số lượng mẫu tối thiểu tại một nút lá (giúp mô hình mượt mà hơn, tránh học thuộc lòng nhiễu).

Đồ án sử dụng kỹ thuật **RandomizedSearchCV** (Tìm kiếm ngẫu nhiên với kiểm định chéo) để xác định bộ tham số tối ưu.



Hình 7: Trực quan hóa cấu trúc Cây quyết định (3 tầng đầu tiên)

Nhận xét: Quan sát cấu trúc 3 tầng đầu tiên của Cây quyết định tại Hình 7, ta có thể rút ra các đặc điểm quan trọng về cách mô hình học dữ liệu:

- **Vai trò tối quan trọng của địa điểm:** Nút gốc (Root Node) và các nút ở tầng thứ hai chủ yếu thực hiện việc phân chia dựa trên các biến định danh cửa hàng (như `Store_20`, `Store_14`, `Store_4`). Điều này cho thấy "Cửa hàng nào"là yếu tố quyết định lớn nhất đến doanh số, phản ánh sự chênh lệch quy mô rất lớn giữa các siêu thị trong hệ thống Walmart.
- **Các yếu tố kinh tế và thời gian:** Sau khi đã phân nhóm được các cửa hàng lớn, mô hình mới bắt đầu xét đến các yếu tố vĩ mô như chỉ số giá tiêu dùng (`CPI`), giá nhiên liệu (`Fuel_Price`) hoặc yếu tố mùa vụ (`Week`). Ví dụ, tại nhánh bên phải (dành riêng cho Store 20), yếu tố quan trọng tiếp theo là `Week`, cho thấy tính mùa vụ tác động mạnh đến cửa hàng này.

- **Hạn chế của mô hình tập trung:** Việc cây quyết định phải dùng nhiều tầng đầu tiên chỉ để "lọc"cửa hàng cho thấy mô hình tập trung đang phải gồng gánh quá nhiều đặc thù riêng biệt của 45 cửa hàng khác nhau. Đây là lý do khiến độ sâu của cây cần phải lớn và dễ dẫn đến quá khớp (overfitting) nếu không kiểm soát tốt.

5.1.2 Mô hình phi tập trung (Decentralized)

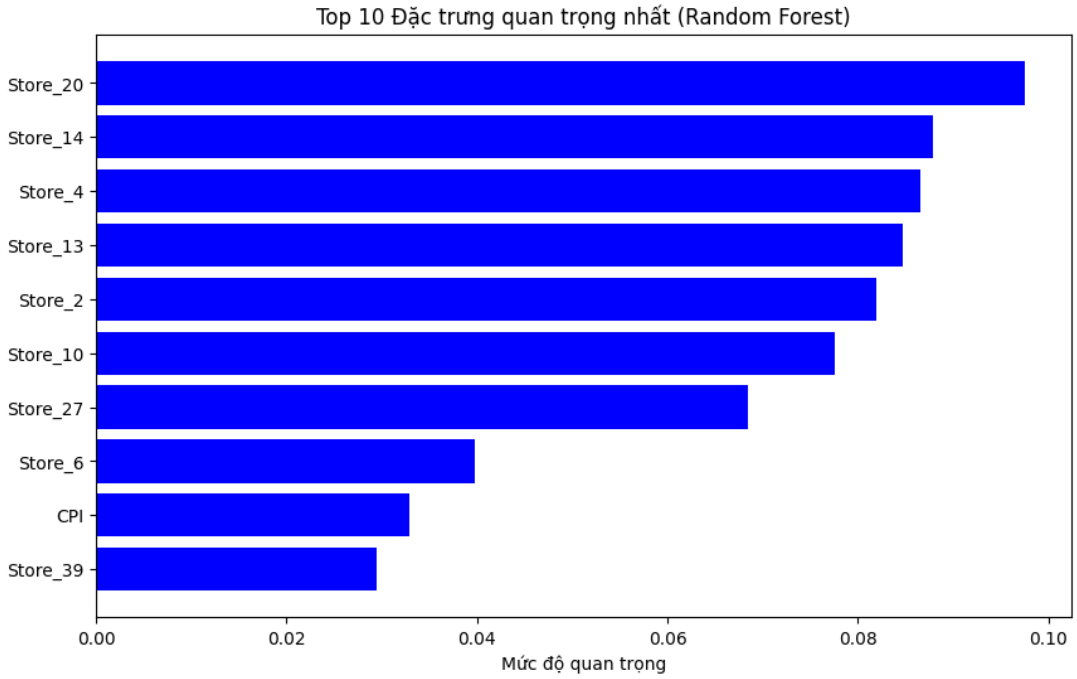
Đồ án huấn luyện 45 cây quyết định độc lập cho từng cửa hàng, cho phép các tham số cây thích nghi riêng với từng tập dữ liệu con.

- **Kết quả:** $RMSE$ giảm xuống còn 117,882, cho thấy sự cải thiện so với mô hình tập trung ($RMSE \approx 120,737$).
- **Nhận xét:** Việc tách riêng từng cửa hàng giúp cây quyết định không bị nhiễu bởi sự đa dạng của toàn mạng lưới. Tuy nhiên, nhược điểm cố hữu của Cây quyết định là **phương sai cao (High Variance)**: một thay đổi nhỏ trong dữ liệu huấn luyện có thể dẫn đến một cây hoàn toàn khác, làm giảm độ ổn định của dự báo.

5.2 Rừng ngẫu nhiên (Random Forest)

5.2.1 Mô hình tập trung (Centralized)

Mô hình được tối ưu hóa bằng cách tinh chỉnh số lượng cây (`n_estimators`), số lượng đặc trưng ngẫu nhiên tại mỗi nút phân chia (`max_features`) và tỷ lệ lấy mẫu Bootstrap (`max_samples`). Việc giới hạn `max_features` giúp giảm sự tương quan giữa các cây, từ đó giảm phương sai tổng thể của mô hình.



Hình 8: Top 10 đặc trưng quan trọng nhất ảnh hưởng đến dự báo (Mô hình Random Forest)

Nhận xét: Quan sát Hình 8, ta thấy sự thống trị tuyệt đối của các biến định danh cửa hàng (được tạo ra từ quá trình One-Hot Encoding) trong việc đóng góp vào quyết định của mô hình:

- Các biến đại diện cho các cửa hàng cụ thể như `Store_20`, `Store_14`, và `Store_4` nắm giữ các vị trí đầu tiên với mức độ quan trọng cao nhất (dao động từ 0.08 đến gần 0.10). Điều này phản ánh thực tế rằng doanh số của Walmart có sự phân hóa rất lớn giữa các địa điểm khác nhau; việc biết được "đây là cửa hàng nào"quan trọng hơn nhiều so với các thông tin khác.
- Chỉ số giá tiêu dùng (`CPI`) là biến kinh tế vĩ mô duy nhất xuất hiện trong Top 10, tuy nhiên mức độ ảnh hưởng thấp hơn đáng kể so với định danh cửa hàng.
- **Ý nghĩa:** Kết quả này cho thấy mô hình tập trung (Centralized) đang cố gắng "học thuộc lòng"đặc tính của từng cửa hàng thông qua mã định danh. Đây là bằng chứng củng cố cho giả thuyết rằng chiến lược **Phi tập trung (Decentralized)** - xây dựng mô hình riêng cho từng cửa hàng - hoặc phương pháp **Phân cụm (Clustering)** sẽ là hướng đi phù hợp hơn để nắm bắt chính xác các đặc thù địa phương này.

5.2.2 Mô hình phi tập trung (Decentralized)

Áp dụng Random Forest riêng biệt cho từng trong số 45 cửa hàng.

- **Kết quả:** Phương pháp này đạt kết quả khá tốt trong thực nghiệm với $RMSE \approx 122,043$, nhờ khả năng chống nhiễu của Random Forest kết hợp với tính cá nhân hóa của chiến lược phi tập trung.
- **Nhược điểm:** Chi phí tính toán và thời gian huấn luyện tăng lên đáng kể (gấp nhiều lần so với Cây quyết định đơn lẻ), đòi hỏi tài nguyên phần cứng lớn hơn khi triển khai thực tế.

5.3 Cây tăng cường Gradient (Gradient-Boosted Tree)

Đây là phương pháp học máy mạnh mẽ (Ensemble Learning), xây dựng các cây quyết định một cách tuần tự (sequential). Cây sau sẽ tập trung học vào phần sai số (residual errors) mà cây trước chưa giải quyết được.

5.3.1 Mô hình tập trung (Centralized)

Áp dụng thuật toán Gradient Boosting (thư viện `scikit-learn`) trên toàn bộ tập dữ liệu.

- **Cấu hình kỹ thuật:** Đồ án thiết lập tốc độ học (`learning_rate`) nhỏ (0.05 - 0.1) kết hợp với số lượng cây lớn để mô hình hội tụ chậm mà chắc. Độ sâu của cây (`max_depth`) được giữ ở mức thấp (3-5) để tạo ra các "weak learners"(người học yếu) nhằm tránh overfitting.
- **Kết quả:** Mô hình đạt hiệu quả vượt trội với $RMSE \approx 91,301$ và $R^2 \approx 0.9737$.
- **Nhận xét:** Gradient Boosting đặc biệt hiệu quả trong việc giảm độ chệch (Bias), nắm bắt tốt các đỉnh doanh số (spikes) vào dịp lễ mà các mô hình khác thường bỏ sót. Đây là mô hình tốt nhất trong số các phương pháp đã thử nghiệm.

5.3.2 Mô hình phi tập trung (Decentralized)

- **Thách thức:** Khi áp dụng Gradient Boosting cho từng cửa hàng riêng lẻ, rủi ro quá khớp (overfitting) tăng cao do lượng dữ liệu huấn luyện cho mỗi cửa hàng bị giới hạn. Mô hình có xu hướng học thuộc lòng các nhiễu (noise) trong quá khứ của cửa hàng đó.
- **Kết quả:** $RMSE \approx 103,251$.
- **Nhận xét:** Trong thực nghiệm này, Gradient Boosting phi tập trung cho kết quả kém ổn định hơn so với mô hình tập trung. Điều này phù hợp với lý thuyết: Gradient Boosting cần lượng dữ liệu đủ lớn để tổng quát hóa tốt các quy luật phức tạp.

5.4 Phân cụm K-means (K-means Clustering)

Để cân bằng giữa chiến lược Tập trung (quá tổng quát) và Phi tập trung (quá chi tiết/nhiễu), em thực hiện phương pháp lai (Hybrid Approach) sử dụng K-means.

5.4.1 Xây dựng đặc trưng phân cụm

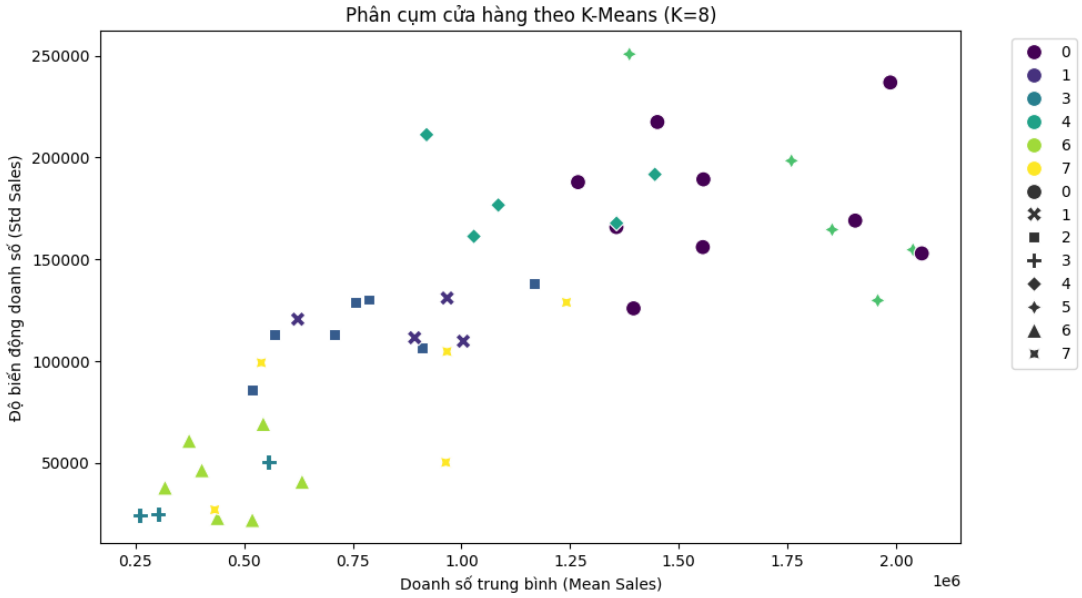
Thay vì sử dụng dữ liệu thô, em trích xuất các đặc trưng đại diện cho hành vi bán hàng của từng cửa hàng (Store Profile). Dựa trên thực nghiệm, bộ đặc trưng tốt nhất bao gồm:

- **Trung bình (Mean):** Phản ánh quy mô doanh số và mức độ kinh tế trung bình (Weekly Sales, CPI, Unemployment).
- **Độ lệch chuẩn (Standard Deviation):** Phản ánh mức độ biến động của doanh số (Volatility). Điều này giúp tách biệt các cửa hàng ổn định với các cửa hàng có tính mùa vụ cao.

5.4.2 Tối ưu hóa số lượng cụm (K)

Thay vì sử dụng phương pháp "khuỷu tay"(Elbow method) truyền thống, em áp dụng phương pháp tối ưu hóa dựa trên hiệu suất dự báo (Prediction-based Optimization).

- Đồ án chạy thử nghiệm với K chạy từ 2 đến 10.
- Với mỗi K, dữ liệu được chia nhóm và một mô hình Random Forest được huấn luyện riêng cho từng nhóm.
- **Kết quả:** Số lượng cụm tối ưu được xác định là $K = 8$, mang lại giá trị R^2 cao nhất trên tập kiểm định. Các cụm này giúp tách biệt chi tiết hơn các nhóm cửa hàng có hành vi doanh số tương đồng.



Hình 9: Biểu đồ phân cụm cửa hàng theo K-Means dựa trên Doanh số trung bình và Độ biến động

Nhận xét: Quan sát Hình 9, thuật toán K-Means ($K = 8$) đã phân tách 45 cửa hàng thành các nhóm có đặc điểm kinh doanh riêng biệt dựa trên hai trục chính:

- **Trục hoành (Doanh số trung bình):** Phân loại quy mô cửa hàng từ nhỏ (dưới 0.5 triệu USD) đến lớn (trên 2.0 triệu USD).
- **Trục tung (Độ biến động):** Phân loại mức độ ổn định. Có những cửa hàng doanh số cao nhưng rất ổn định (biến động thấp), ngược lại có những cửa hàng doanh số trung bình nhưng biến động rất mạnh (do tính mùa vụ cao hoặc khuyến mãi thất thường).
- **Hiệu quả phân cụm:** Các nhóm được hình thành khá gọn gàng. Ví dụ: Nhóm các cửa hàng nhỏ (Góc dưới bên trái) có doanh số thấp và ít biến động. Ngược lại, nhóm các siêu thị lớn (Góc trên bên phải) có doanh số rất cao và độ biến động cũng lớn tương ứng. Việc gom nhóm này giúp mô hình học máy (như Random Forest sau đó) có thể áp dụng chiến lược dự báo chuyên biệt cho từng nhóm hành vi, thay vì dùng một mô hình chung cho tất cả, từ đó nâng cao độ chính xác tổng thể.

5.5 Phân cụm dựa trên mật độ (DBSCAN Clustering)

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) được áp dụng để xử lý các cửa hàng ngoại lai (Outliers) mà K-means không xử lý tốt.

5.5.1 Cơ chế hoạt động

Khác với K-means buộc mọi cửa hàng phải thuộc về một cụm, DBSCAN gom nhóm các cửa hàng có đặc tính "gần nhau"(dựa trên khoảng cách ϵ và số lượng láng giềng tối thiểu `min_samples`). Các cửa hàng có hành vi quá khác biệt sẽ được gán nhãn là Nhiễu (Noise/-1).

5.5.2 Tinh chỉnh tham số và Kết quả

Đồ án sử dụng vòng lặp ngẫu nhiên để tìm bộ tham số (ϵ, `min_samples`) tối ưu:

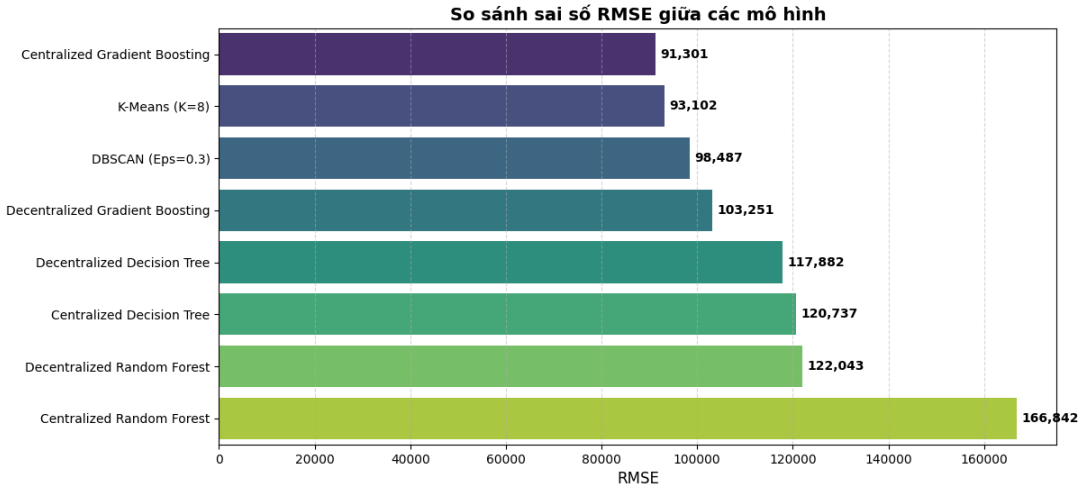
- Các cửa hàng được phân vào các cụm chính sẽ được dự báo bằng mô hình chung của cụm đó.
- Các cửa hàng bị coi là "Nhiễu"(Singleton clusters) sẽ được huấn luyện bằng mô hình riêng biệt (Decentralized) để đảm bảo độ chính xác.
- **Kết quả:** Phương pháp này đạt $RMSE \approx 98,487$, cho thấy khả năng tự động phát hiện và xử lý ngoại lai giúp cải thiện độ chính xác tổng thể so với các phương pháp gom nhóm cứng nhắc.

5.6 Tổng hợp kết quả các phương pháp học máy

Bảng 5 tổng hợp kết quả thực nghiệm của các mô hình học máy, được sắp xếp theo độ chính xác từ cao xuống thấp.

Bảng 5: So sánh hiệu quả các mô hình Học máy trên tập kiểm định

Mô hình	Chiến lược	RMSE	R2 Score
Gradient Boosting	**Centralized**	**91,301**	**0.9737**
K-Means ($K = 8$) + RF	Hybrid	93,102	0.9727
DBSCAN ($Eps = 0.3$) + RF	Hybrid	98,487	0.9694
Gradient Boosting	Decentralized	103,251	0.9664
Decision Tree	Decentralized	117,882	0.9562
Decision Tree	Centralized	120,737	0.9540
Random Forest	Decentralized	122,043	0.9530
Random Forest	Centralized	166,842	0.9122



Hình 10: Biểu đồ so sánh sai số RMSE giữa các phương pháp Học máy

Kết luận: Qua thực nghiệm trên tập dữ liệu này, mô hình **Gradient Boosting tập trung (Centralized)** cho kết quả vượt trội nhất với $RMSE \approx 91,301$ và $R^2 \approx 0.97$.

Đáng chú ý, phương pháp lai ghép **Phân cụm K-Means** cũng đạt hiệu quả rất cao ($RMSE \approx 93,102$), tiệm cận với mô hình tốt nhất. Ngược lại, chiến lược phi tập trung (Decentralized) cho Random Forest trong lần chạy này không đạt hiệu quả như kỳ vọng ($RMSE \approx 122,043$), cho thấy việc chia nhỏ dữ liệu quá mức cho từng cửa hàng có thể làm giảm khả năng tổng quát hóa của mô hình Random Forest khi dữ liệu huấn luyện cục bộ bị hạn chế.

6 Đánh giá hiệu quả và Trực quan hóa kết quả

Trong chương này, em tổng hợp và đánh giá toàn diện hiệu năng của các mô hình đã triển khai. Mục tiêu là xác định mô hình tối ưu nhất để đưa vào ứng dụng thực tế, đồng thời kiểm định độ bền vững (robustness) của mô hình trước sự thay đổi của dữ liệu đầu vào.

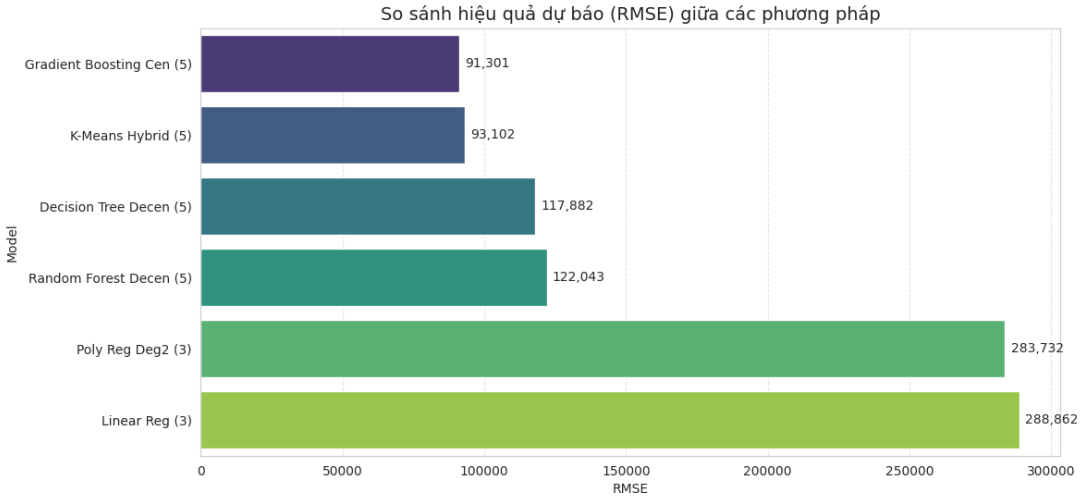
6.1 Tổng hợp kết quả thực nghiệm

Bảng 6 và Hình 11 dưới đây tóm tắt hiệu suất của các nhóm mô hình chính: Truyền thống (Mục 3) và Học máy (Mục 5).

- **Nhóm Truyền thống (Regression):** Có $RMSE$ dao động quanh mức $280,000$. Mặc dù Hồi quy đa thức (Polynomial) đã cải thiện so với Hồi quy tuyến tính, sai số vẫn còn rất lớn do không xử lý được tính phi tuyến phức tạp và sự tương tác giữa các biến.
- **Nhóm Học máy (Machine Learning):** Đạt bước nhảy vọt về độ chính xác. Cụ thể, mô hình **Gradient Boosting (Centralized)** đạt sai số thấp nhất ($RMSE \approx 91,301$), giảm hơn **3 lần** so với các phương pháp truyền thống.
- **Nhóm Chuỗi thời gian (Time Series - Chương 4):** Do thực hiện trên dữ liệu tổng hợp (Aggregated Data) với thang đo doanh số hàng triệu USD, nên không đưa vào biểu đồ so sánh trực tiếp này. Tuy nhiên, như đã phân tích ở mục 4, mô hình Holt-Winters cũng cho thấy khả năng bắt nhịp mùa vụ rất tốt.

Bảng 6: Bảng xếp hạng hiệu năng các mô hình tiêu biểu

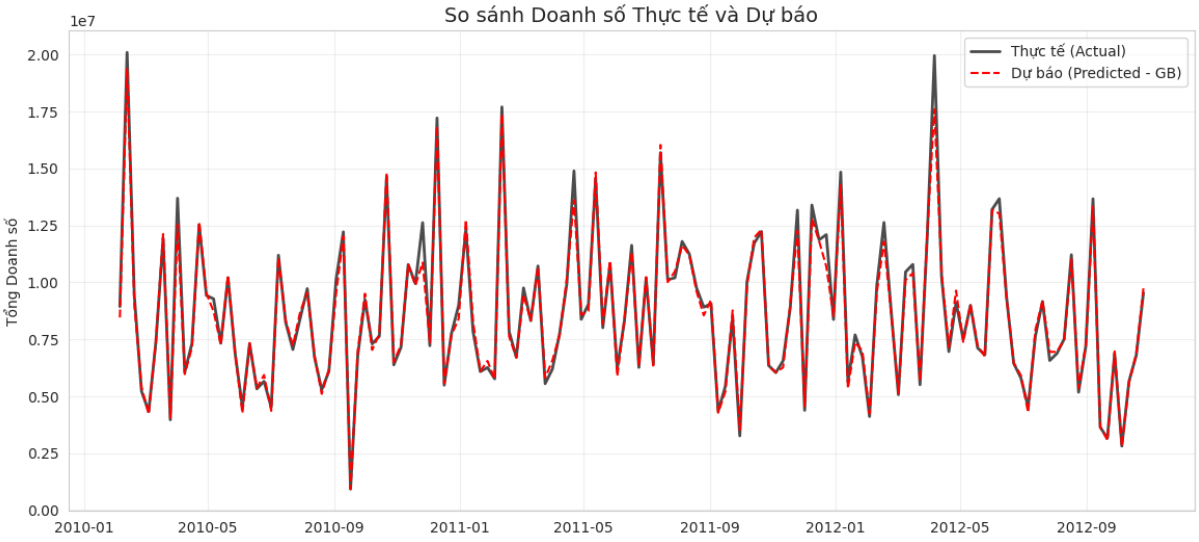
Nhóm phương pháp	**Mô hình**	**RMSE**	**R2 Score**
Học máy (Tốt nhất)	Gradient Boosting (Centralized)	**91,301**	**0.9737**
Học máy	K-Means Hybrid	93,102	0.9727
Học máy	Decentralized Random Forest	122,043	0.9530
Truyền thống (Tốt nhất)	Polynomial Regression (Deg 2)	283,732	0.7460
Truyền thống	Linear Regression	288,862	0.7368



Hình 11: Biểu đồ so sánh RMSE giữa các phương pháp

6.2 So sánh giá trị dự báo và thực tế (Predicted vs. Actual Values)

Để kiểm chứng khả năng nắm bắt xu hướng của mô hình tốt nhất (**Gradient Boosting Centralized**), em trực quan hóa dữ liệu dự báo so với dữ liệu thực tế trên tập kiểm tra (Test Set). Do việc hiển thị hàng ngàn điểm dữ liệu của 45 cửa hàng sẽ gây rối mắt, Hình 12 dưới đây biểu diễn **Tổng doanh số hàng tuần** của toàn bộ hệ thống.



Hình 12: Khả năng nắm bắt xu hướng của mô hình Gradient Boosting (Dữ liệu tổng hợp)

Nhận xét:

- **Độ khớp xu hướng (Trend Capture):** Đường dự báo (màu đỏ) bám rất sát đường thực tế (màu đen), kể cả ở các điểm đảo chiều đột ngột. Điều này chứng tỏ mô hình đã học tốt các quy luật mùa vụ.
- **Xử lý đỉnh (Peak Handling):** Mô hình dự báo khá chính xác biên độ của các đỉnh doanh số lớn (vào dịp Lễ Tạ Ơn và Giáng Sinh). Đây là ưu điểm vượt trội của

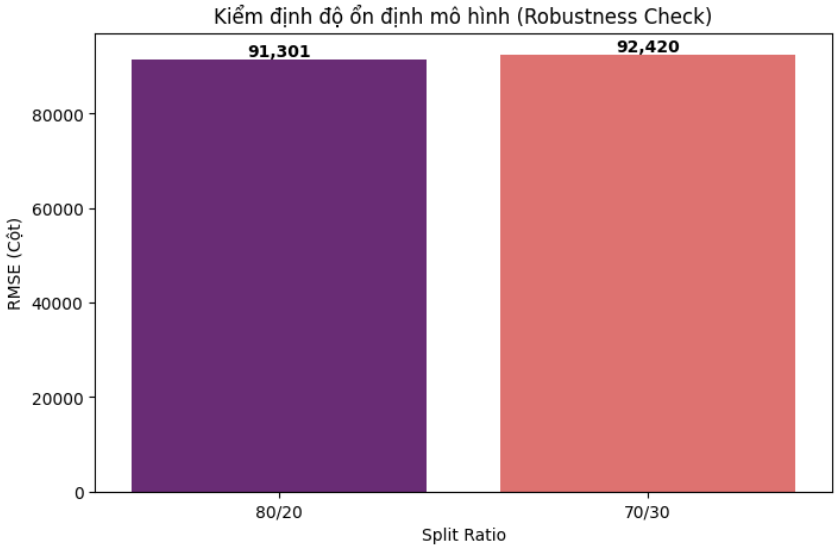
Gradient Boosting so với các mô hình làm mượt (Smoothing) ở Mục 4 thường bị trễ pha hoặc không đạt đỉnh.

6.3 Đánh giá độ ổn định theo tỷ lệ chia dữ liệu (Robustness to Split Ratio)

Một mô hình tốt không chỉ cần chính xác mà còn phải ổn định (robust), không phụ thuộc quá nhiều vào cách chia tập dữ liệu. Đồ án thực hiện phân tích độ nhạy bằng cách thay đổi tỷ lệ Train/Test từ **80/20** sang **70/30** và đánh giá lại mô hình Gradient Boosting.

Bảng 7: Kết quả kiểm định độ ổn định (Robustness Test)

Tỷ lệ Train/Test	RMSE	R2 Score
80/20	91,301	0.9737
70/30	92,420	0.9733



Hình 13: Biến động sai số RMSE khi thay đổi tỷ lệ chia dữ liệu

Kết luận: Khi giảm lượng dữ liệu huấn luyện xuống (tỷ lệ 70/30 - tương đương giảm khoảng 600 tuần dữ liệu học), sai số RMSE có sự gia tăng nhẹ (từ $\approx 91k$ lên $\approx 92k$) nhưng vẫn duy trì ở mức thấp hơn nhiều so với các mô hình khác. Chỉ số R^2 vẫn đạt trên 0.97. Điều này khẳng định mô hình Gradient Boosting có tính ổn định cao (High Robustness) và không bị quá khớp (Overfitting) vào một tập dữ liệu cụ thể nào.

7 Kết luận và Kiến nghị

7.1 Kết luận

Đồ án này đã thực hiện một quy trình toàn diện nhằm giải quyết bài toán dự báo doanh số bán lẻ cho hệ thống 45 cửa hàng Walmart, đi từ việc phân tích khám phá dữ liệu, áp dụng các phương pháp thống kê truyền thống đến việc triển khai các mô hình học máy tiên tiến. Các kết quả thực nghiệm cho phép rút ra những kết luận quan trọng sau:

1. **Về tính chất dữ liệu:** Dữ liệu doanh số bán lẻ mang tính mùa vụ (Seasonality) rất mạnh và chịu tác động lớn từ các sự kiện ngày lễ (Holiday Events) như Lễ Tạ Ơn và Giáng Sinh. Các biến kinh tế vĩ mô (CPI, Thất nghiệp, Giá nhiên liệu) có tác động nhưng mối tương quan tuyến tính là không cao, đòi hỏi các mô hình phi tuyến để khai thác hiệu quả.

2. **Về hiệu quả của các phương pháp:**

   - **Phương pháp Thống kê (Mục 3 & 4):** Các mô hình hồi quy truyền thống (Linear, Lasso, Ridge) gặp khó khăn trong việc giảm sai số ($RMSE \approx 280,000$) do hạn chế trong việc mô hình hóa các mối quan hệ phức tạp. Trong khi đó, mô hình chuỗi thời gian Holt-Winters cho thấy khả năng nắm bắt nhịp điệu mùa vụ tốt nhưng lại thiếu linh hoạt khi tích hợp các biến ngoại sinh.
   - **Phương pháp Học máy (Mục 5):** Đây là bước đột phá của nghiên cứu. Việc chuyển đổi bài toán chuỗi thời gian thành bài toán học có giám sát (Supervised Learning) thông qua kỹ thuật Feature Engineering đã mang lại hiệu quả vượt trội. Trong đó, mô hình **Gradient Boosting (Centralized)** được xác định là mô hình tối ưu nhất với $RMSE \approx 91,301$ và $R^2 \approx 0.97$, vượt qua cả Random Forest và các phương pháp lai ghép (Hybrid K-Means).

3. **Về chiến lược mô hình hóa:** So sánh giữa chiến lược Tập trung (Centralized) và Phi tập trung (Decentralized), kết quả cho thấy chiến lược Tập trung hoạt động hiệu quả hơn đối với Gradient Boosting trên tập dữ liệu này. Điều này chứng tỏ việc gộp chung dữ liệu giúp mô hình học được các quy luật tổng quát tốt hơn là việc chia nhỏ dữ liệu quá manh mún cho từng cửa hàng, vốn dễ dẫn đến rủi ro quá khớp (overfitting) khi dữ liệu huấn luyện cục bộ bị hạn chế.

7.2 Hạn chế và hướng phát triển

Mặc dù đã đạt được những kết quả khả quan, đồ án vẫn tồn tại một số hạn chế nhất định cần được khắc phục trong các nghiên cứu tương lai:

7.2.1 Hạn chế

- **Giới hạn về dữ liệu:** Nghiên cứu mới chỉ dừng lại ở các biến số cơ bản có sẵn trong bộ dữ liệu Walmart. Các yếu tố quan trọng khác ảnh hưởng đến doanh số bán lẻ như: thông tin tồn kho, các chương trình khuyến mãi cụ thể, dữ liệu đối thủ cạnh tranh hay xu hướng tìm kiếm trên internet chưa được đưa vào mô hình.

- **Tối ưu hóa siêu tham số:** Do giới hạn về tài nguyên tính toán và thời gian, quá trình tinh chỉnh tham số (Hyperparameter Tuning) mới chỉ thực hiện ở mức cơ bản (RandomizedSearchCV). Không gian tìm kiếm tham số chưa đủ rộng để khai thác tối đa tiềm năng của các thuật toán như Gradient Boosting.

- **Khả năng giải thích:** Các mô hình Ensemble (như Random Forest, Gradient Boosting) thường được ví như "hộp đen"(Black-box). Việc giải thích cặn kẽ tại sao mô hình đưa ra một dự báo cụ thể tại một thời điểm nhất định vẫn còn hạn chế so với các mô hình thống kê minh bạch.

7.2.2 Hướng phát triển

Để nâng cao hơn nữa độ chính xác và tính ứng dụng thực tế, em đề xuất các hướng nghiên cứu tiếp theo:

1. **Áp dụng Deep Learning (Học sâu):** Triển khai các kiến trúc mạng nơ-ron chuyên dụng cho chuỗi thời gian như **LSTM (Long Short-Term Memory)** hoặc **GRU (Gated Recurrent Unit)**. Các mô hình này có khả năng ghi nhớ các phụ thuộc dài hạn (long-term dependencies) tốt hơn các mô hình cây quyết định, đặc biệt hữu ích khi dữ liệu lịch sử đủ dài.

2. **Mô hình lai ghép nâng cao (Advanced Hybrid Models):** Kết hợp sức mạnh của ARIMA (để xử lý phần tuyến tính) và Neural Networks (để xử lý phần phi tuyến của sai số) nhằm tạo ra một hệ thống dự báo toàn diện hơn.

3. **Tích hợp dữ liệu thời gian thực:** Xây dựng quy trình cập nhật dữ liệu (Data Pipeline) để mô hình có thể tái huấn luyện định kỳ hoặc học tăng cường (Online Learning) khi có dữ liệu bán hàng mới phát sinh hàng tuần.

Tài liệu

[1] Nicolas Vandeput. *Data Science for Supply Chain Forecasting*. 2nd Edition, De Gruyter, 2021.

[2] Maxime C. Cohen, Paul-Emile Gras, Arthur Pentecoste, Renyu Zhang. *Demand Prediction in Retail: A Practical Guide to Leverage Data and Predictive Analytics*. Springer Series in Supply Chain Management, 2022.

[3] Charles W. Chase Jr. *Demand-Driven Forecasting: A Structured Approach to Forecasting*. 2nd Edition, John Wiley & Sons, 2013.

[4] Rob J Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. 2nd Edition, OTexts: Melbourne, Australia, 2018.

[5] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 2nd Edition, O'Reilly Media, 2019.

[6] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd Edition, Springer, 2009.

[7] Leo Breiman. Random Forests. *Machine Learning*, 45(1), 5-32, 2001.

[8] Jerome H. Friedman. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5), 1189-1232, 2001.

[9] Pedregosa, F., et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830, 2011.